Pablo Caricio

RELATÓRIO TÉCNICO - VISÃO COMPUTACIONAL

Transformers, CLIP, CNNs e GANs aplicados a problemas de visão

Projeto: EcoVision AI

Disciplina: Deep Learning and Vision - Computer Vision

Versão final - resultados validados localmente e execução integral dos quatro notebooks reproduzida no Google Colab com GPU Tesla T4.

2026

Resumo

Este relatório documenta quatro atividades práticas de visão computacional desenvolvidas no projeto EcoVision AI. A primeira atividade implementa componentes de Transformer e um Vision Transformer (ViT) do zero para classificação do dataset RealWaste, comparando-o com um ViT pré-treinado. A segunda atividade utiliza CLIP para ranking semântico e busca textual no corpus ADS-16 sem treinamento supervisionado adicional. A terceira aplica transfer learning com EfficientNet-B0 em um dataset de sete classes, incluindo limpeza, deduplicação, feature extraction e fine-tuning. A quarta analisa um estudo de caso de classificação de radiografias de tórax, implementa uma Conditional GAN, diagnostica mode collapse, aplica estratégias de mitigação e avalia o efeito de augmentation sintética no recall da classe COVID-19. Os resultados foram reproduzidos após a reorganização do projeto e os quatro notebooks finais foram executados integralmente no Google Colab com GPU Tesla T4, reproduzindo as métricas e artefatos principais.

Palavras-chave: visão computacional; Vision Transformer; CLIP; transfer learning; EfficientNet; GAN; COVID-19; embeddings.

1. Introdução e metodologia geral

O objetivo do projeto é exercitar decisões de engenharia em visão computacional: seleção de arquitetura, preparação de dados, definição de métricas, avaliação crítica e justificativa técnica. Em todas as atividades, o código é tratado como meio para produzir evidência experimental, e não como fim isolado. A estrutura final do projeto foi organizada por domínio em src/vit, src/clip, src/cnn e src/xray, mantendo resultados e checkpoints dos experimentos.

Os experimentos foram inicialmente executados em ambiente local Windows com Python 3.12 e PyTorch. Após a reorganização estrutural, os checkpoints de ViT, EfficientNet e ResNet/cGAN foram carregados novamente e as avaliações principais reproduziram as mesmas métricas. Em seguida, os quatro notebooks finais foram executados no Google Colab com GPU Tesla T4. Os notebooks localizaram o projeto em /content, reconstruíram automaticamente os datasets/corpus quando necessário e reutilizaram os checkpoints existentes, concluindo sem traceback e preservando os resultados esperados.

Atividade	Problema	Abordagem principal	Evidência central
A1	Classificação de resíduos RealWaste	ViT do zero + ViT pré-treinado	55,26% vs 86,54% de accuracy
A2	Semântica em anúncios ADS-16	CLIP zero-shot / retrieval	24 conceitos, 600 imagens, 8 consultas
A3	Classificação de 7 categorias	EfficientNet-B0 + transfer learning	98,49% de accuracy
A4.1	COVID em radiografias	ResNet-18 + cGAN	Recall COVID 55,56% -> 38,89% com sintéticos
A4.2	Fluxo de tráfego urbano	Análise metodológica	Domain shift, leakage e generalização por câmera

2. Atividade 1 - Vision Transformers

2.1 Problema e dataset

Foi escolhido o RealWaste, conjunto público com 4.752 imagens de resíduos reais distribuídas em nove classes: Cardboard, Food Organics, Glass, Metal, Miscellaneous Trash, Paper, Plastic, Textile Trash e Vegetation. O domínio é adequado para comparar a capacidade de generalização de um Transformer treinado do zero com um modelo que reutiliza pré-treinamento.

O split foi estratificado em 70% treino, 15% validação e 15% teste, resultando em 3.326, 713 e 713 imagens, respectivamente. No treino foram aplicados RandomResizedCrop, horizontal flip, rotação leve e ColorJitter, seguidos da normalização do ImageNet.

2.2 Implementação do mecanismo de attention

O mecanismo de Scaled Dot-Product Attention foi implementado diretamente em PyTorch. A similaridade entre Query e Key é escalada por sqrt(d_k), normalizada com softmax e usada para combinar os Values. A Multi-Head Attention utiliza três heads independentes, cada um com projeções próprias de Q, K e V, e concatena suas saídas antes da projeção final (VASWANI et al., 2017).

```
Attention(Q,K,V) = softmax((Q K^T) / sqrt(d_k)) V

embed_dim = 192
num_heads = 3
d_head = 64
```

O TransformerEncoderBlock emprega arquitetura pre-norm, residual connections e feed-forward de duas camadas. A sequência visual é criada por PatchEmbedding: uma imagem 224x224 é dividida em patches 16x16, produzindo 196 tokens; somando o CLS token, a sequência possui 197 tokens. Um positional embedding aprendível é adicionado porque a self-attention, isoladamente, não preserva a posição original dos patches.

2.3 ViT do zero

Parâmetro	**Valor**
Image size	224 x 224
Patch size	16 x 16
Patches	196
Tokens com CLS	197
Embedding	192
Heads	3
Encoder blocks	4
MLP dim	768
Dropout	0,1
Parâmetros	1.967.241
Optimizer	AdamW
Learning rate	3e-4
Weight decay	0,05
Máx. epochs	15
Early stopping	4

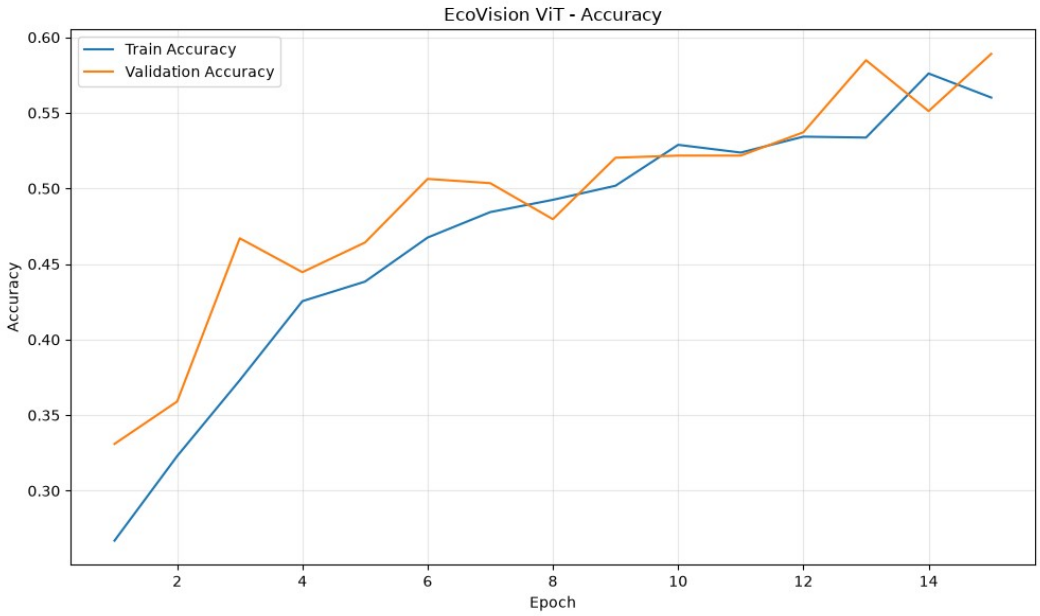


Figura 1 - Curvas de accuracy do ViT treinado do zero.

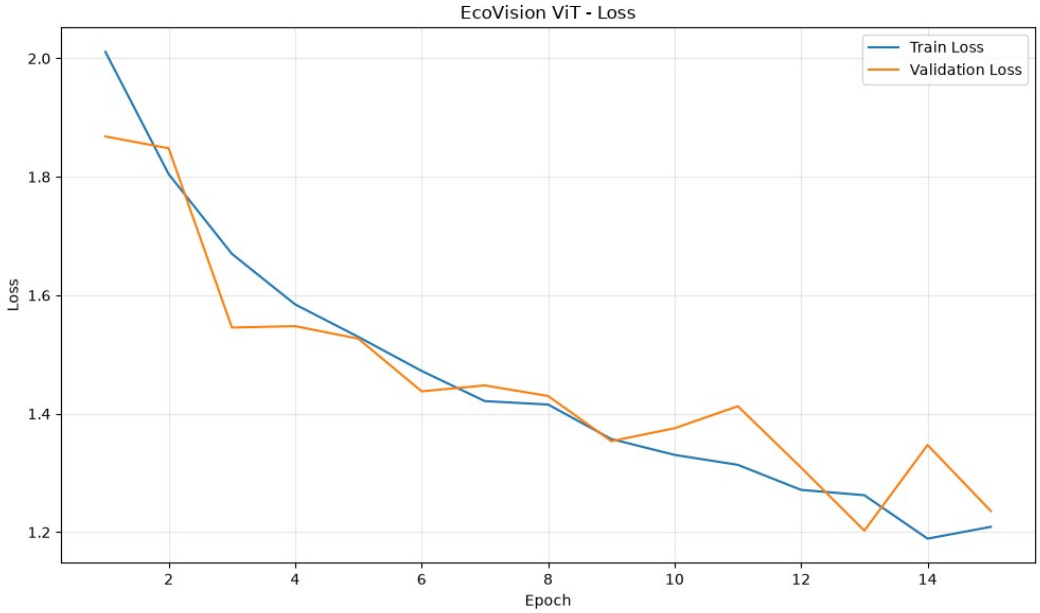


Figura 2 - Curvas de loss do ViT treinado do zero.

O melhor checkpoint ocorreu na época 13. No teste, o ViT scratch obteve accuracy de 55.26%, F1 weighted de 53.67% e F1 macro de 52.44%. As classes Miscellaneous Trash e Textile Trash apresentaram maiores dificuldades, enquanto Plastic apresentou recall de 76.09%.

2.4 Attention maps

Foi selecionado um exemplo da classe Plastic corretamente classificado e a atenção do CLS token para os patches foi extraída do último Encoder Block. Os três heads apresentaram padrões espaciais distintos: o head 0 distribuiu atenção por várias regiões internas do objeto; o head 1 enfatizou principalmente regiões de contorno e a porção inferior, com alguma resposta ao fundo; e o head 2 concentrou pesos em regiões internas de maior contraste. Esses padrões sugerem que projeções distintas podem aprender relações espaciais complementares. A visualização é interpretativa: attention weights indicam onde o mecanismo distribuiu peso, mas não devem ser tratados automaticamente como explicação causal da decisão.

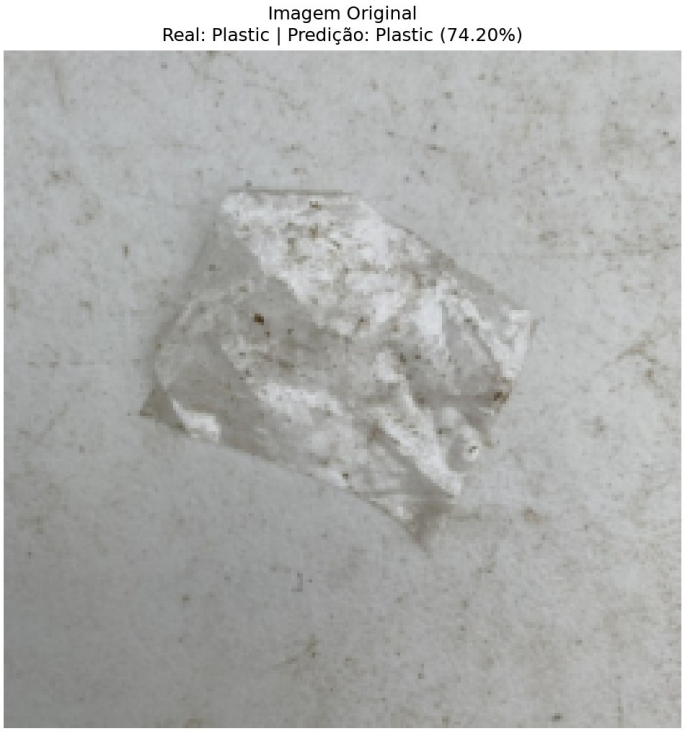


Figura 3 - Imagem original usada na análise de attention.

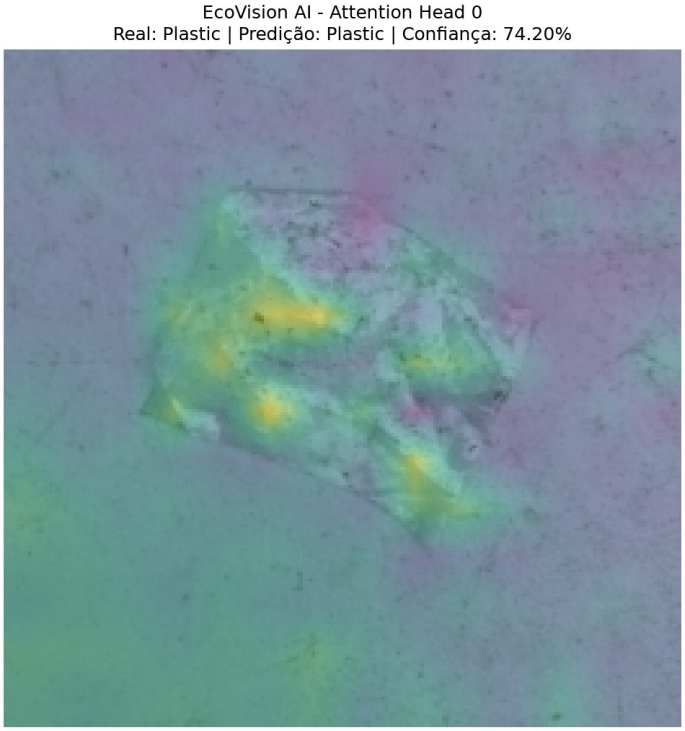


Figura 4 - Attention map sobreposto - head 0.

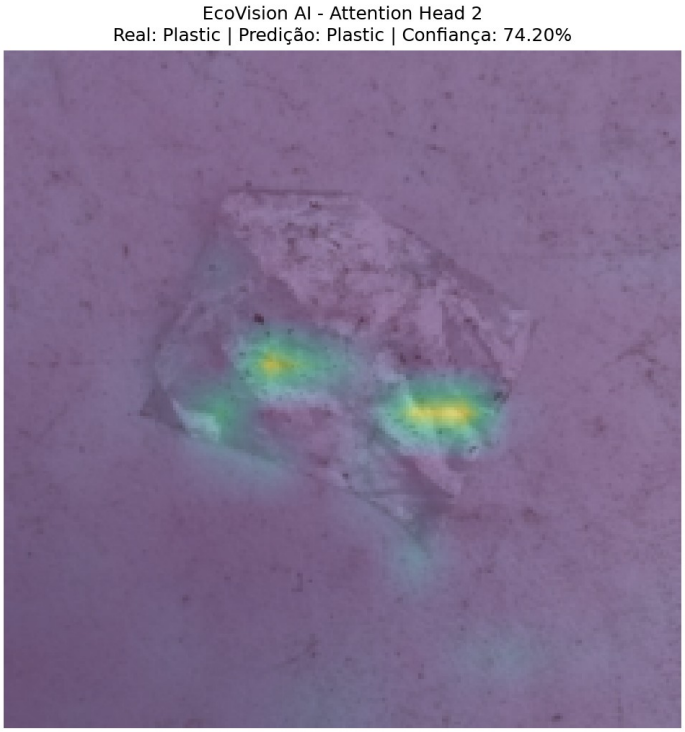


Figura 5 - Attention map sobreposto - head 2.

2.5 ViT pré-treinado e comparação

A segunda solução usa vit_tiny_patch16_224. O classification head foi substituído para nove classes. Primeiro, o backbone foi congelado por duas épocas com learning rate 1e-3; depois, o modelo inteiro foi liberado para fine-tuning por até oito épocas com learning rate 1e-5 e weight decay 0,01. Essa estratégia preserva inicialmente as representações pré-treinadas e depois permite adaptação fina ao domínio.

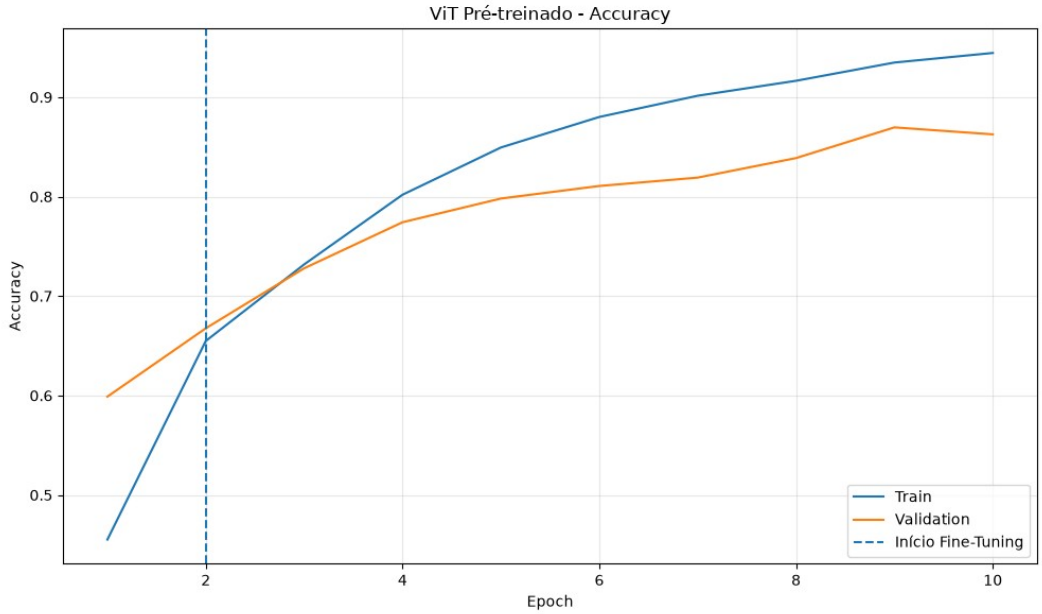


Figura 6 - Accuracy do ViT pré-treinado durante feature extraction/fine-tuning.

Modelo	Accuracy teste	F1 weighted	F1 macro
ViT do zero	55.26%	53.67%	52.44%
ViT pré-treinado	86.54%	86.55%	87.24%

O ganho de accuracy foi de 31.28 pontos percentuais. No contexto deste dataset, o resultado evidencia a importância do pré-treinamento para ViTs quando o volume de dados é relativamente pequeno. O resultado é consistente com o trabalho original do ViT, que destaca forte desempenho após pré-treinamento em grandes coleções (DOSOVITSKIY et al., 2020).

2.6 BERT, DeiT, Swin e comparação com CNNs

BERT e ViT compartilham o Transformer Encoder, mas recebem entradas e objetivos de pré-treinamento diferentes. No BERT original, o Masked Language Modeling (MLM) maximiza a probabilidade dos tokens mascarados condicionada ao contexto bidirecional; o

trabalho original também inclui Next Sentence Prediction (NSP) como objetivo auxiliar. No ViT original, os patches de imagem são tratados como tokens e o pré-treinamento é supervisionado para classificação, minimizando a loss de classificação em grandes coleções rotuladas antes do fine-tuning no domínio alvo. Assim, BERT otimiza representação contextual de linguagem a partir de previsão de tokens, enquanto ViT aprende representações visuais discriminativas a partir de rótulos de imagem (DEVLIN et al., 2018; DOSOVITSKIY et al., 2020).

DeiT busca reduzir a dependência de dados externos de grande escala e introduz uma estratégia de distillation token, permitindo transferir conhecimento de um professor para o Transformer (TOUVRON et al., 2020). Swin Transformer organiza a representação hierarquicamente e limita a self-attention a janelas locais deslocadas, reduzindo custo e permitindo conexão entre janelas em tarefas de diferentes escalas (LIU et al., 2021).

CNNs possuem vieses indutivos locais, compartilhamento de pesos e hierarquia espacial explícita, sendo frequentemente competitivas em conjuntos menores. ViTs modelam relações globais entre patches e se beneficiam fortemente de pré-treinamento em larga escala. No EcoVision, essa diferença aparece no contraste entre o ViT scratch e o ViT pré-treinado.

3. Atividade 2 - Reconhecimento semântico com CLIP

3.1 Corpus e preparação

Foi usado um subconjunto representativo de 600 imagens do ADS-16, selecionando cinco imagens por usuário para 120 usuários, com alternância aproximada entre POS e NEG. Antes da seleção, foi aplicada deduplicação global por SHA-256. O corpus de origem considerado possuía 2.396 arquivos, 47 duplicatas exatas e 2.349 arquivos únicos; o corpus final possui 600 hashes únicos.

A deduplicação por SHA-256 elimina cópias binariamente idênticas, mas não remove necessariamente near-duplicates resultantes de recompressão, resize ou pequenas alterações. Essa limitação foi observada na inspeção das buscas e deve ser considerada em trabalhos futuros.

3.2 CLIP e alinhamento multimodal

O modelo openai/clip-vit-base-patch32 foi utilizado apenas para inferência. CLIP aprende um espaço compartilhado entre imagens e textos por pré-treinamento contrastivo,

aproximando pares correspondentes e afastando pares incompatíveis. Isso permite usar linguagem natural como interface para conceitos visuais sem treinar um novo classificador supervisionado (RADFORD et al., 2021).

```
image_embedding = normalize(vision_encoder(image))
text_embedding  = normalize(text_encoder(text))
similarity = image_embedding @ text_embedding.T
```

Foram usadas 24 descrições de conceitos. Para cada uma das 600 imagens foram calculadas similaridades com todas as descrições, totalizando 14.400 comparações.

3.3 Threshold e ranking

Estatística	Similaridade
min	0.1149
mean	0.1902
median	0.1890
std	0.0218
Percentil 75	0.2031
Percentil 90	0.2177
Percentil 95	0.2284
max	0.2943

O threshold 0,22 foi escolhido de forma empírica porque fica próximo ao percentil 90 da distribuição observada e mantém volume suficiente de correspondências para um ranking interpretável. O score CLIP é similaridade, não probabilidade.

Threshold	Pares acima do corte	Percentual
0.22	1254	8.71%
0.23	639	4.44%
0.24	316	2.19%
0.25	158	1.10%

Posição	Conceito	Frequência	Percentual	Score médio
1	an animal	133	22.17%	0.2394
2	a pet	109	18.17%	0.2422
3	a food product	101	16.83%	0.2360
4	a person	100	16.67%	0.2295
5	a human face	93	15.50%	0.2331

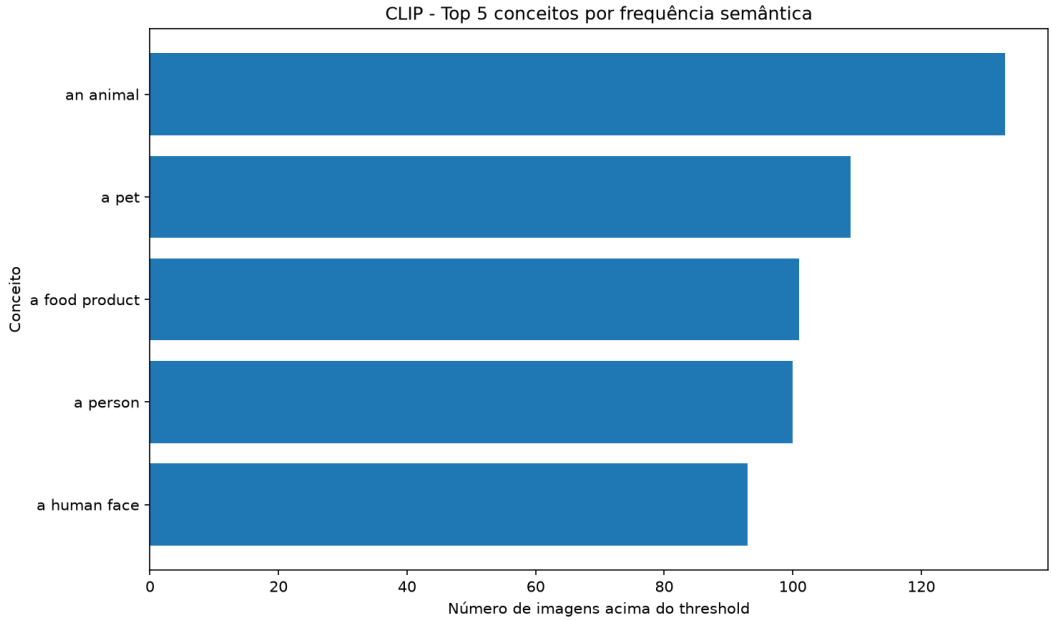


Figura 7 - Top-5 conceitos por frequência semântica.

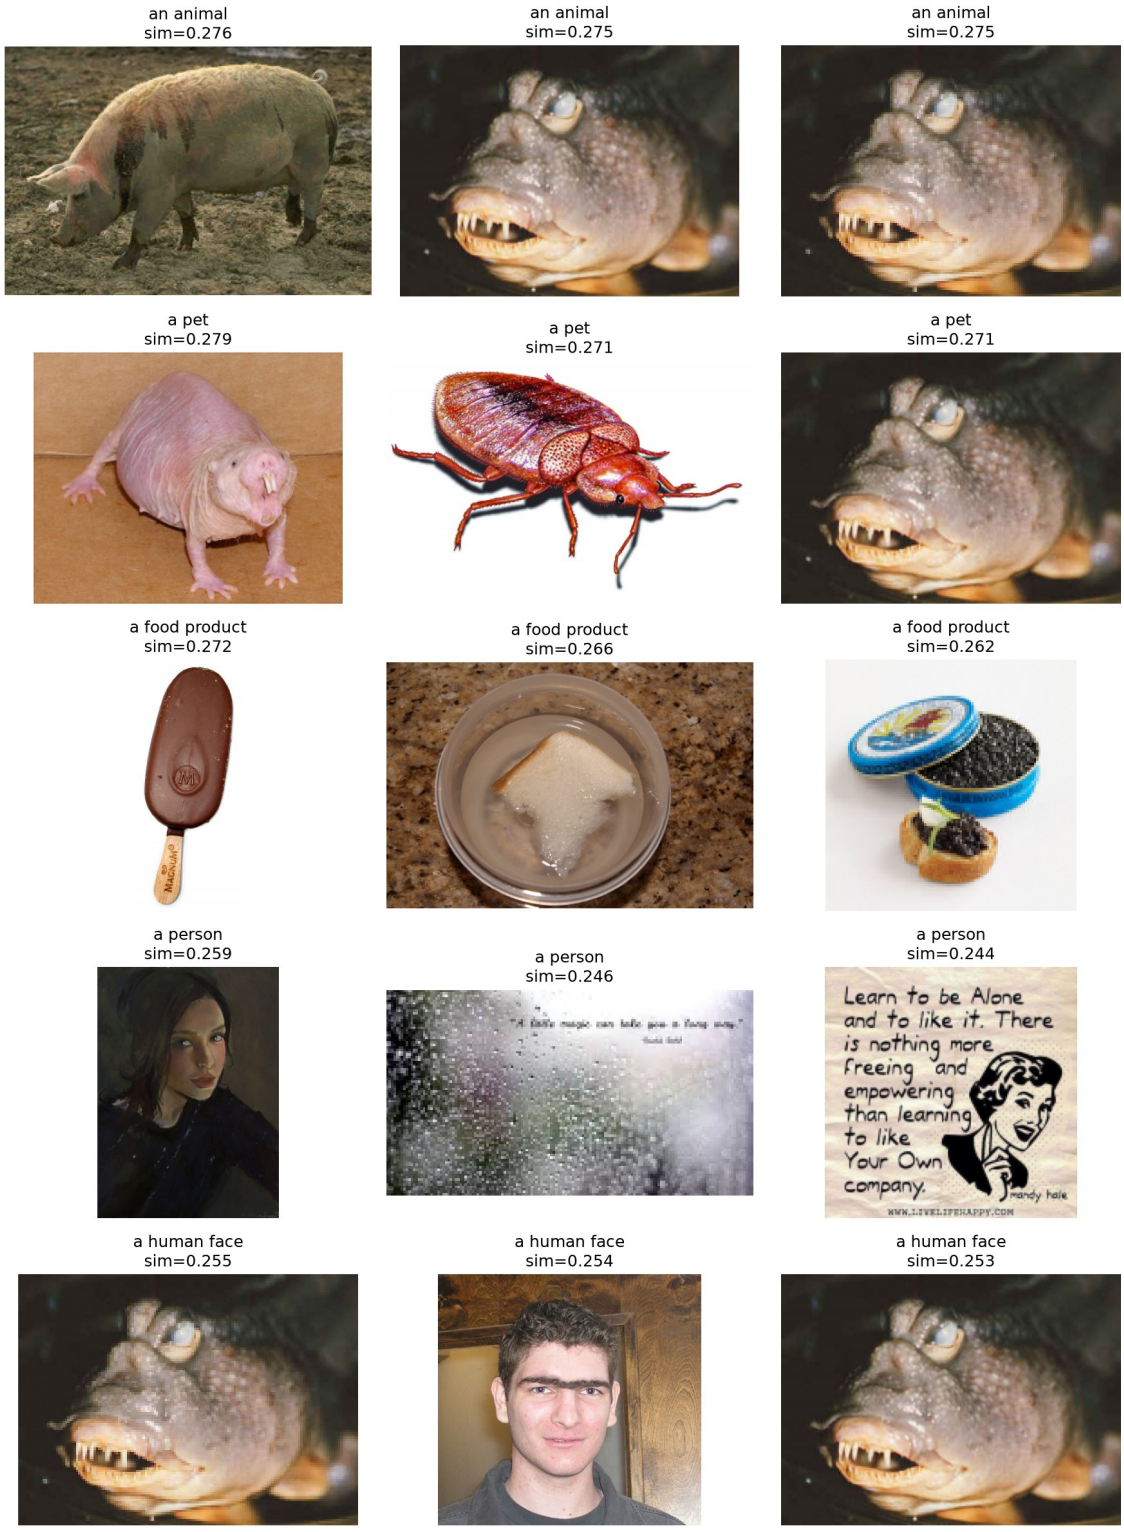


Figura 8 - Exemplos visuais dos cinco conceitos mais frequentes.

3.4 Busca semântica

A busca textual gera um embedding para a consulta e ordena as 600 imagens pela cosine similarity, retornando Top-5. Foram executadas oito consultas variando em especificidade e abstração.

Consulta	Análise
a person	Parcialmente boa: recupera pessoas e representações humanas, mas inclui ruído contextual.
an animal	Muito boa: os resultados recuperados são fortemente coerentes com o conceito de animal.
a food product	Boa com ruído: os primeiros resultados são adequados, mas há correspondências inferiores menos coerentes.
a person outdoors	Muito boa: a combinação pessoa + ambiente externo aparece de forma consistente.
a child playing sports	Parcial: o melhor resultado é forte, enquanto outros satisfazem apenas partes da composição.
a person using an electronic device	Fraca/parcial: aparecem eletrônicos sem pessoa usando-os e pessoas sem ação clara.
a relaxing outdoor scene	Muito boa: cenas externas/naturais compatíveis com a ideia abstrata de relaxamento.
a happy social moment	Boa/parcial: captura felicidade e pessoas, mas nem todos os resultados expressam interação social clara.



Figura 9 - Exemplo de busca semântica: a person outdoors.



Figura 10 - Exemplo de consulta composta com resultados parciais.

Consultas visuais diretas, como an animal, foram mais consistentes; consultas composicionais podem recuperar apenas parte da semântica. O resultado reforça que

embedding similarity captura proximidade global de significado, mas não garante que todos os predicados de uma frase sejam simultaneamente satisfeitos.

3.5 CLIP versus BERT

BERT usa tokenização, padding e attention mask para construir representações contextuais de linguagem. O padding permite formar batches retangulares; a attention mask marca posições válidas para que tokens de preenchimento não sejam tratados como conteúdo. CLIP também possui um encoder textual Transformer, mas sua projeção final é treinada para alinhar texto ao espaço visual. BERT original, por sua vez, é um modelo de linguagem e não é pré-treinado para alinhar diretamente texto e imagem (DEVLIN et al., 2018; RADFORD et al., 2021).

4. Atividade 3 - CNN pré-treinada

4.1 Preparação e deduplicação

O dataset de sete classes (bike, cars, cats, dogs, flowers, horses e human) possuía uma estrutura duplicada que podia levar uma busca recursiva a contar 3.606 arquivos. Selecionando a raiz correta foram identificadas 1.803 imagens válidas. A deduplicação SHA-256 removeu 39 duplicatas exatas, produzindo 1.764 imagens únicas. A deduplicação foi realizada antes do split para prevenir data leakage entre treino e teste.

O split final foi 70/15/15, com 1.234 imagens de treino, 265 de validação e 265 de teste.

4.2 Augmentation e modelo

No treino foram usadas quatro estratégias: RandomResizedCrop com scale 0,8-1,0; horizontal flip; rotação de 10 graus; ColorJitter leve de brilho, contraste e saturação. As transformações foram escolhidas para aumentar robustez sem destruir a semântica das classes. Crops ou rotações agressivas poderiam cortar objetos ou criar orientações improváveis; alterações excessivas de cor poderiam reduzir pistas discriminativas, especialmente em flores.

A EfficientNet-B0 foi escolhida por combinar boa eficiência computacional, pesos ImageNet e capacidade adequada para sete classes e Colab T4. A família EfficientNet foi projetada com escalonamento composto de profundidade, largura e resolução (TAN; LE, 2019).

O head original de 1.000 classes foi substituído por Linear(1280, 7). Na primeira fase, o backbone ficou congelado por duas épocas com learning rate 1e-3. Na segunda, todo o modelo foi liberado para fine-tuning com learning rate 1e-4, weight decay 0,01 e early stopping de três épocas.

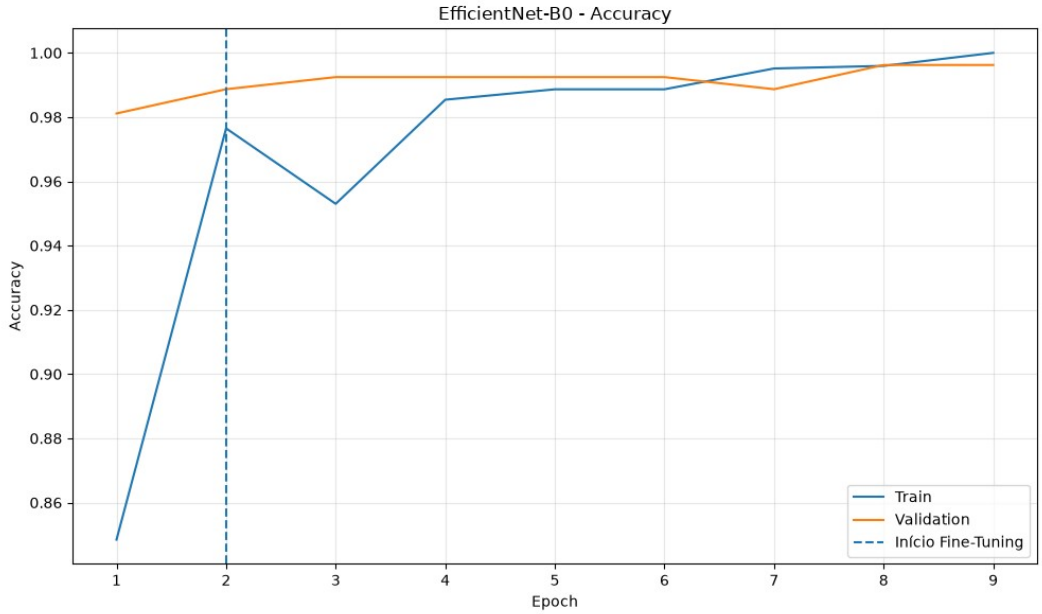


Figura 11 - Accuracy da EfficientNet-B0 durante transfer learning.

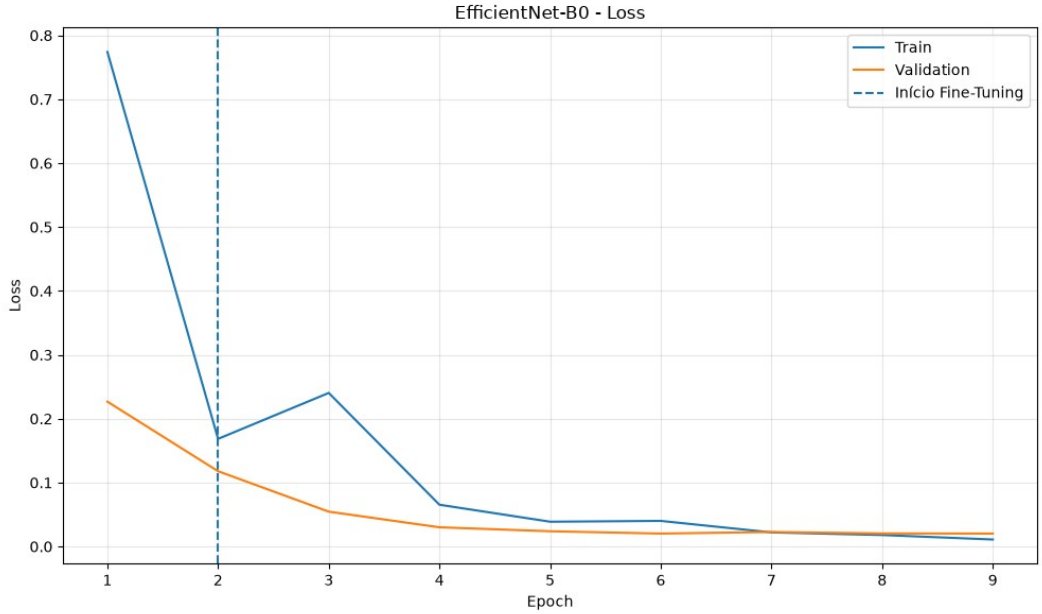


Figura 12 - Loss da EfficientNet-B0 durante transfer learning.

4.3 Resultados

Métrica	Resultado
Accuracy	98.49%
Precision weighted	98.51%
Recall weighted	98.49%
F1 weighted	98.50%
F1 macro	98.48%

Classe	Accuracy	Acertos
bike	98.15%	53/54
cars	98.41%	62/63
cats	96.67%	29/30
dogs	96.77%	30/31
flowers	100.00%	32/32
horses	100.00%	28/28
human	100.00%	27/27

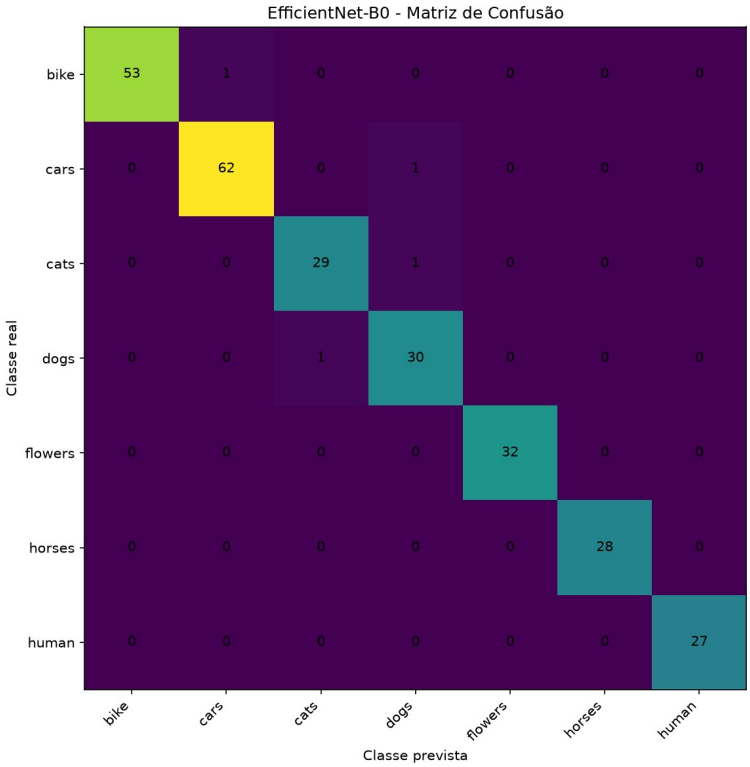


Figura 13 - Matriz de confusão da EfficientNet-B0 no teste.

O modelo classificou corretamente 261 de 265 imagens de teste. O resultado elevado deve ser interpretado junto com a metodologia de deduplicação: sem remover duplicatas antes do split, a métrica poderia ser artificialmente inflada por vazamento de imagens idênticas. O desempenho também é favorecido pela proximidade das categorias com objetos comuns do ImageNet e pelo forte ponto de partida do transfer learning.

5. Atividade 4.1 - Estudo de caso de radiografias

5.1 Diagnóstico do projeto original

O cenário do enunciado descreve 1.200 radiografias: 840 Normal, 240 Pneumonia e 120 COVID-19, split 80/20 sem estratificação, ResNet-18 sem pré-treinamento, SGD com learning rate fixo de 0,01, 15 épocas, sem augmentation e avaliação apenas por accuracy. O treino atingiu 93% e a validação 61%.

Problema	Diagnóstico técnico	Impacto esperado
Dataset desbalanceado	A classe Normal domina a loss e pode mascarar desempenho ruim em COVID.	Maior risco de falsos negativos na classe minoritária.

Problema	Diagnóstico técnico	Impacto esperado
Split sem estratificação	A proporção de classes pode variar entre treino e avaliação.	Métricas instáveis e minoria mal representada.
ResNet-18 do zero	Poucos dados para aprender toda a representação profunda.	Overfitting e generalização limitada.
Sem augmentation	Pouca variação durante treino.	Menor robustez a mudanças plausíveis de aquisição/posicionamento.
LR fixo 0,01	Sem adaptação do passo de otimização.	Treinamento pode oscilar ou convergir inadequadamente.
Accuracy apenas	Métrica global favorece classe majoritária.	Pode esconder baixa sensibilidade para COVID.
Gap 93% vs 61%	Diferença grande treino-validação.	Forte evidência de overfitting.

5.2 Baseline controlado

Foi reconstruído um conjunto com a mesma distribuição de 1.200 imagens a partir do COVID-19 Radiography Database, validando arquivos e removendo duplicatas exatas. O split foi estratificado em 70/15/15: treino 840 (84 COVID, 588 Normal, 168 Pneumonia), validação 180 e teste 180. Foi usada ResNet-18 pré-treinada com head de três classes, AdamW, learning rate 1e-4, weight decay 1e-4, augmentation médico leve e early stopping.

Métrica baseline	Resultado
Accuracy	95.00%
Macro F1	88.86%
Macro Recall	84.26%
COVID Recall	55.56%
COVID detectados	10/18
COVID não detectados	8/18

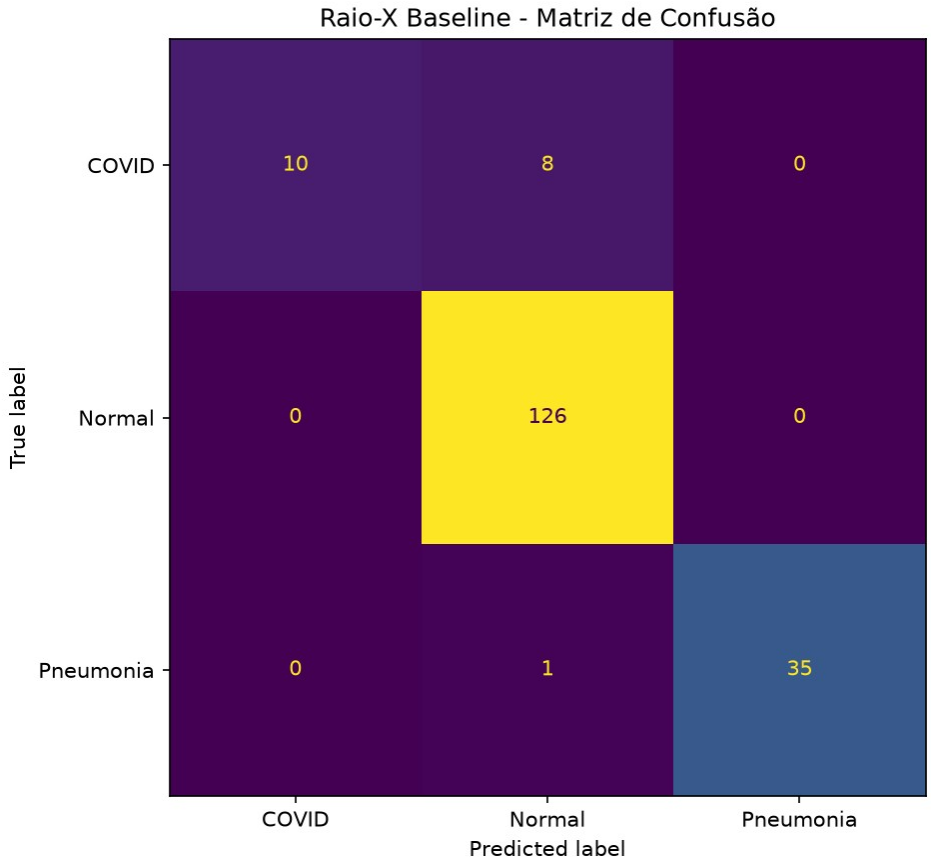


Figura 14 - Matriz de confusão do baseline de radiografias.

O resultado evidencia a limitação da accuracy: 95% parece alto, mas o modelo detectou somente 10 dos 18 casos COVID. Para uma classe de interesse clínico, recall/sensibilidade e falsos negativos precisam ser analisados explicitamente.

5.3 Conditional GAN e loop adversarial

Para endereçar a escassez de COVID, foi implementada uma Conditional DCGAN. O Generator recebe vetor latente de dimensão 100 e embedding da classe; ConvTranspose2d aumenta a resolução até 64x64 e Tanh produz imagem grayscale em [-1,1]. O Discriminator recebe a imagem concatenada a um mapa condicionado pela classe e retorna um logit treinado com BCEWithLogitsLoss. O princípio adversarial segue o framework de Goodfellow et al. (2014).

O loop alterna atualização de D e G. Durante a etapa de D, fake.detach() impede gradientes de alterar G. Durante a etapa de G, as imagens falsas recebem target real, incentivando o Generator a produzir exemplos que o Discriminator não consiga distinguir. Um WeightedRandomSampler equilibra a exposição às classes no treino da GAN.

5.4 Mode collapse e mitigação

A cGAN base apresentou queda progressiva da diversidade e imagens muito semelhantes dentro de cada classe, compatível com mode collapse. A primeira mitigação reduziu o learning rate do Discriminator para 1e-4, aplicou one-sided label smoothing (real=0,9) e instance noise inicial de 0,05 com decaimento até zero. Isso tornou o jogo adversarial menos dominado por D, mas não aumentou a diversidade final.

Na terceira versão foi adicionada Mode-Seeking Regularization, que maximiza a razão entre a distância das imagens geradas e a distância dos vetores latentes correspondentes. A estratégia se inspira no objetivo de incentivar o Generator a explorar diferentes modos em vez de ignorar z (MAO et al., 2019).

Experimento	Diversidade COVID final	D(real) final	D(fake) final
cGAN base	0,0207	0,7857	0,2234
Mitigada	0,0189	0,6076	0,2998
Mode-Seeking	0,0261	0,5740	0,3105

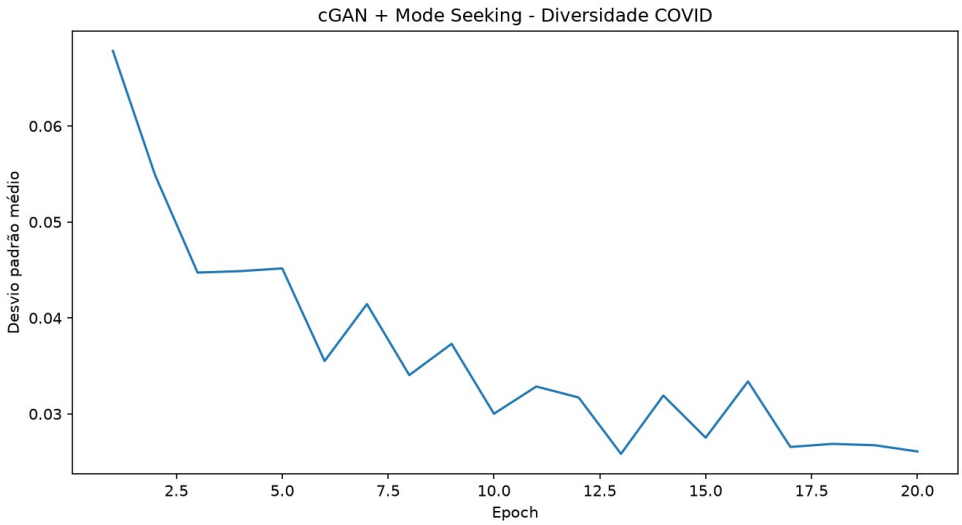


Figura 15 - Evolução da diversidade COVID na cGAN com Mode-Seeking.

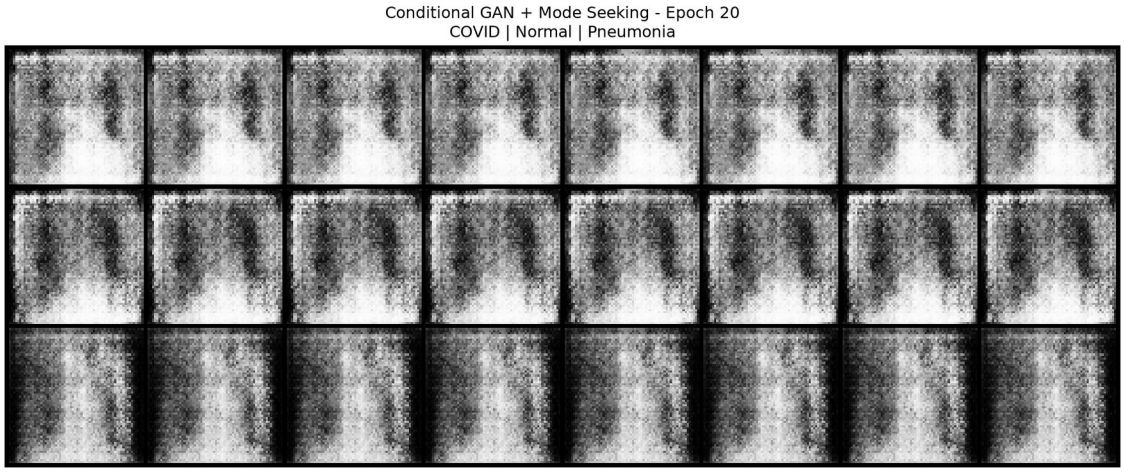


Figura 16 - Amostras da cGAN Mode-Seeking na época 20.

A diversidade final aumentou cerca de 26% em relação à cGAN base e 38% em relação à primeira mitigação, mas a inspeção visual ainda revela forte similaridade entre amostras da mesma classe. A conclusão é de melhoria parcial, e não de resolução completa do mode collapse. A maior diversidade ocorreu no início, quando as imagens tinham baixa qualidade, mostrando que diversidade isolada não mede realismo.

5.5 Augmentation sintética e resultado

Foram geradas 84 imagens COVID sintéticas, elevando a classe COVID do treino de 84 para 168 exemplos, igualando-a a Pneumonia sem inundar o dataset com exemplos artificiais. O mesmo classificador e hiperparâmetros do baseline foram reutilizados, mantendo validação e teste 100% reais.

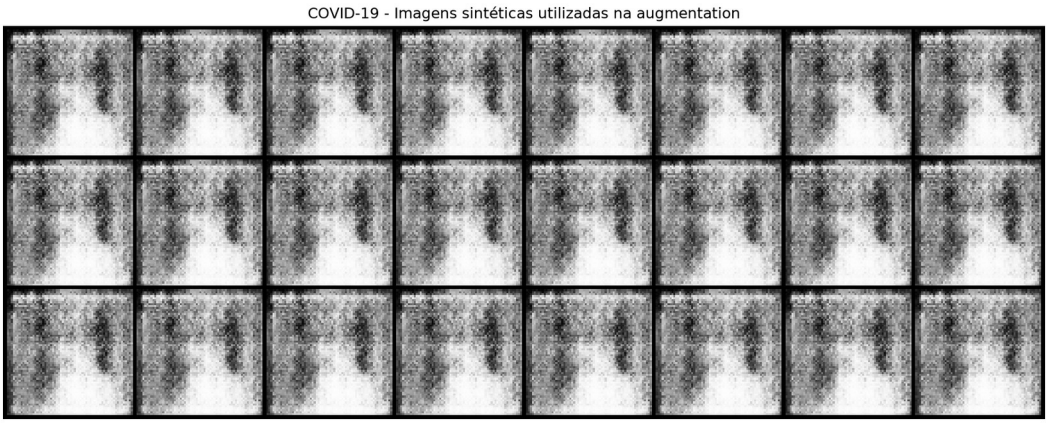


Figura 17 - Preview das 84 imagens COVID sintéticas usadas no experimento.

Métrica	Baseline	Real + sintético	Diferença
Accuracy	95.00%	93.33%	-1.67 pp
Macro F1	88.86%	83.35%	-5.51 pp
Macro Recall	84.26%	78.70%	-5.56 pp
COVID Recall	55.56%	38.89%	-16.67 pp

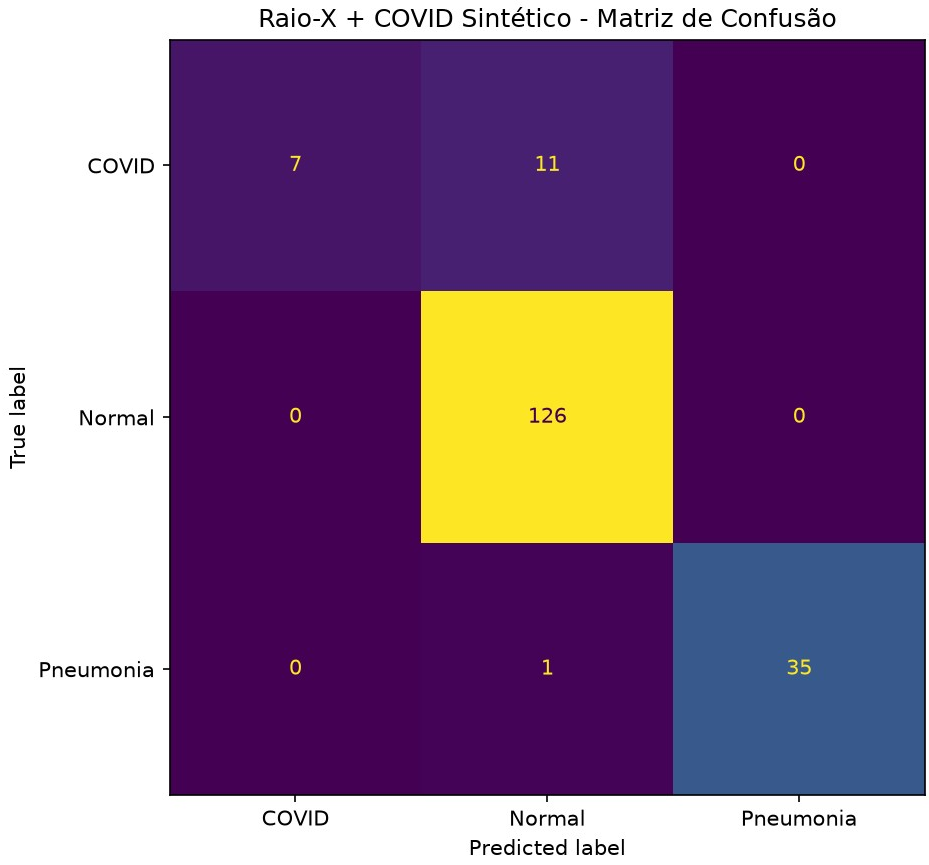


Figura 18 - Matriz de confusão após augmentation sintética.

A augmentation sintética piorou o recall COVID de 55,56% (10/18) para 38,89% (7/18). O resultado é coerente com a baixa diversidade da GAN e demonstra que aumentar a quantidade de imagens não significa necessariamente acrescentar informação útil. Com apenas 18 casos COVID no teste, cada imagem equivale a aproximadamente 5,56 pontos percentuais de recall; portanto, a queda de 16,67 pp representa três casos adicionais não detectados. A evidência é válida para o experimento, mas não permite generalização universal sobre GANs médicas.

5.6 Plano integrado de melhoria

- Modelo: manter transfer learning e avaliar, em trabalhos futuros, pesos pré-treinados em domínio médico/radiológico para reduzir o domain shift do ImageNet.
- Métricas: usar recall/sensibilidade por classe, precision, F1, macro F1, macro recall e matriz de confusão; acompanhar explicitamente falsos negativos COVID.
- Dados: deduplicação antes do split, estratificação e, quando disponível, separação por paciente/hospital para evitar leakage; validação externa em instituições diferentes.
- Augmentation real: manter transformações leves e plausíveis, evitando distorções anatômicas.
- Augmentation sintética: exigir evidência de diversidade, realismo e ganho downstream; considerar WGAN-GP, difusão, maior resolução e avaliação especializada.
- Adoção clínica: exigir validação externa, análise de falsos negativos, revisão por especialistas, teste prospectivo e monitoramento de drift; não adotar com base apenas em accuracy.

6. Atividade 4.2 - Tráfego urbano

O estudo descreve ResNet-50 pré-treinada em ImageNet, fine-tuned em 800 frames de 12 câmeras para classificar fluxo como livre, moderado ou congestionado. A validação foi de 78%, mas surgiram falhas em chuva, noite e ângulos não vistos. Como exigido, esta parte é somente analítica, sem implementação.

Problema	Risco	Abordagem
Poucos dados / baixa cobertura	800 frames não representam a diversidade de clima, horário e locais.	Ampliar dados por condição e medir cobertura por cenário.
Somente 12 câmeras	O modelo pode aprender identidade, fundo e perspectiva das câmeras.	Separar treino/teste por câmera e avaliar em câmeras totalmente novas.
Frames correlacionados	Frames consecutivos podem ser quase idênticos e vazar entre splits.	Agrupar por sequência/tempo/câmera antes da divisão.
Domain shift chuva/noite	Distribuição visual muda em iluminação, reflexos e visibilidade.	Coletar dados reais dessas condições e usar augmentations específicas.
Ângulos não vistos	A perspectiva altera escala e densidade aparente.	Treinar com maior variedade de ângulos e validar generalização cross-camera.

Problema	Risco	Abordagem
ImageNet versus fluxo	ImageNet aprende objetos; fluxo depende de densidade, ocupação e relações espaciais.	Fine-tuning mais profundo, dados específicos de tráfego e features temporais.

O risco central do transfer learning aqui não é a incapacidade de reconhecer veículos, mas a diferença entre reconhecer objetos e inferir estado de fluxo. Uma avaliação robusta deve responder se o modelo aprendeu congestionamento ou se memorizou cenários/câmeras. Um protocolo forte separaria câmeras inteiras entre treino e teste e avaliaria por condição operacional.

7. Reprodutibilidade e conclusão geral

As quatro atividades mostram que o desempenho depende tanto da arquitetura quanto da metodologia. No RealWaste, o pré-treinamento elevou substancialmente o desempenho do ViT. No ADS-16, CLIP permitiu recuperação semântica sem fine-tuning, mas consultas composicionais evidenciaram limitações. Na CNN, limpeza e deduplicação foram essenciais para interpretar corretamente uma accuracy muito alta. No estudo médico, a comparação entre accuracy e recall expôs o risco de métricas agregadas, e a augmentation sintética demonstrou que dados gerados de baixa diversidade podem piorar o desempenho downstream.

A reprodutibilidade foi verificada no Google Colab com GPU Tesla T4. O A1 reproduziu o ViT scratch e o ViT pré-treinado, incluindo attention maps e ganho de 31,28 pontos percentuais de accuracy. O A2 reconstruiu um corpus ADS-16 de 600 imagens sem duplicatas exatas, carregou CLIP em CUDA e gerou ranking e buscas semânticas. O A3 reconstruiu o dataset deduplicado de 1.764 imagens e reproduziu 98,49% de accuracy no teste. O A4 carregou os checkpoints do baseline e das três cGANs, validou a geração de 84 imagens COVID sintéticas e reproduziu a comparação final de COVID recall: 55,56% no baseline versus 38,89% com augmentation sintética (-16,67 pp).

8. Uso de ferramentas de IA

Ferramentas de IA generativa, incluindo ChatGPT (OpenAI, 2026), foram utilizadas como apoio na organização do código, revisão conceitual, elaboração de explicações, estruturação dos notebooks e documentação. Os experimentos, métricas e artefatos apresentados derivam das execuções do projeto e foram conferidos com os arquivos de

resultados, checkpoints e execução integral dos quatro notebooks no Google Colab com GPU Tesla T4. A responsabilidade pela verificação técnica, pelas decisões finais e pela submissão acadêmica permanece do aluno.

Referências

DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv:1810.04805, 2018. Disponível em: https://arxiv.org/abs/1810.04805.

DOSOVITSKIY, A. et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. arXiv:2010.11929, 2020. Disponível em: https://arxiv.org/abs/2010.11929.

GOODFELLOW, I. et al. Generative Adversarial Networks. arXiv:1406.2661, 2014. Disponível em: https://arxiv.org/abs/1406.2661.

LIU, Z. et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. arXiv:2103.14030, 2021. Disponível em: https://arxiv.org/abs/2103.14030.

MAO, Q. et al. Mode Seeking Generative Adversarial Networks for Diverse Image Synthesis. CVPR, 2019. Disponível em: https://openaccess.thecvf.com/content_CVPR_2019/html/Mao_Mode_Seeking_Generative_Adversarial_Networks_for_Diverse_Image_Synthesis_CVPR_2019_paper.html.

RADFORD, A. et al. Learning Transferable Visual Models From Natural Language Supervision. arXiv:2103.00020, 2021. Disponível em: https://arxiv.org/abs/2103.00020.

SINGLE, S.; IRANMANESH, S.; RAAD, R. RealWaste: A Novel Real-Life Data Set for Landfill Waste Classification Using Deep Learning. Dataset RealWaste, UCI Machine Learning Repository, 2023. Disponível em: https://archive.ics.uci.edu/dataset/908/realwaste.

TAN, M.; LE, Q. V. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML, 2019. Disponível em: https://proceedings.mlr.press/v97/tan19a.html.

TOUVRON, H. et al. Training data-efficient image transformers & distillation through attention. arXiv:2012.12877, 2020. Disponível em: https://arxiv.org/abs/2012.12877.

VASWANI, A. et al. Attention Is All You Need. arXiv:1706.03762, 2017. Disponível em: https://arxiv.org/abs/1706.03762.

COVID-19 Radiography Database. Dataset utilizado para a construção do experimento de radiografias. Kaggle.

ADS-16 Computational Advertising Dataset. Dataset utilizado no experimento de reconhecimento semântico.

ENUNCIADO DA DISCIPLINA. Atividades e rubrica de Deep Learning and Vision - Computer Vision, 2026. Inclui referências clínicas e de tráfego indicadas pelo professor.

OPENAI. ChatGPT. Ferramenta de IA generativa utilizada como apoio à organização, revisão conceitual e documentação do projeto. 2026. Disponível em: https://chatgpt.com/. Acesso em: 28 set. 2026.

NOUR; TARIQ. Estudo de 2023 em Scientific Reports sobre classificação de COVID-19 em radiografias, referência indicada no enunciado da disciplina. Disponível em: https://www.nature.com/articles/s41598-023-37743-4.

MEEGLE. Transfer Learning for Traffic Analysis. Referência indicada no enunciado para o estudo de caso de tráfego urbano. Disponível em: https://www.meegle.com/en_us/topics/transfer-learning/transfer-learning-for-traffic-analysis.

Apêndice A - Checklist final da rubrica

A rubrica oficial contém 26 critérios binários (Demonstrou / Não demonstrou). Após a revisão final dos notebooks, resultados e relatório, os 26 critérios possuem evidência explícita. A tabela abaixo mapeia cada item à principal evidência produzida no projeto.

Área	Critério	Evidência principal	Status
1. CNN	CNN pré-treinada, head adaptado e feature extraction	EfficientNet-B0 ImageNet; head 1280→7; backbone congelado; 8.967 parâmetros treináveis.	Demonstrado
1. CNN	Curvas e accuracy global/por classe	Curvas de loss/accuracy; teste 98,49%; accuracy das 7 classes e matriz de confusão.	Demonstrado
1. CNN	≥3 estratégias de augmentation justificadas	4 augmentations: crop, flip, rotação e ColorJitter, justificadas por domínio/classe.	Demonstrado
1. CNN	Feature extraction versus fine-tuning	Duas fases explicitadas: head-only e fine-tuning completo com learning rate menor.	Demonstrado
1. CNN	Justificativa do modelo pré-treinado	EfficientNet-B0: eficiente, 7 classes, domínio próximo ao ImageNet e compatível com T4.	Demonstrado
2. Transformer	Scaled dot-product e multi-head attention do zero	Módulos PyTorch testáveis; Q/K/V independentes por head; concatenação das saídas.	Demonstrado
2. Transformer	Attention heatmap + interpretação	Mapas do CLS para patches; heads 0/1/2 interpretados por regiões e com ressalva de não causalidade.	Demonstrado
2. Transformer	TransformerEncoderBlock completo	MHA + FFN de duas camadas + LayerNorm + residual connections, arquitetura pre-norm.	Demonstrado
2. Transformer	Positional encoding e justificativa	Positional embedding aprendível; explicação de que self-attention isolada não preserva posição.	Demonstrado
2. Transformer	Diferenças entre pré-treinamento BERT e ViT	MLM/NSP no BERT original versus classificação supervisionada no ViT original.	Demonstrado
3. ViT	Patch embedding + CLS + posição + logits	224×224, patch 16, 196 patches + CLS = 197 tokens; saída de 9 logits.	Demonstrado
3. ViT	ViT scratch + attention maps + regiões emergentes	ViT 1.967.241 parâmetros; mapas de 3 heads e interpretação escrita.	Demonstrado
3. ViT	ViT pré-treinado + head + comparação	vit_tiny_patch16_224; head 192→9; scratch 55,26% versus pré-treinado 86,54%.	Demonstrado
3. ViT	Análise DeiT e Swin	DeiT: eficiência de dados/destilação; Swin: hierarquia e shifted windows.	Demonstrado
3. ViT	Quando ViT ou CNN é preferível	Discussão de viés indutivo local, volume de dados, relações globais e custo.	Demonstrado
3. ViT	Tabela scratch versus pré-treinado + justificativa	Tabela quantitativa e ganho de 31,28 pp, relacionado ao tamanho do RealWaste.	Demonstrado
4. CLIP	Alinhamento multimodal e contrastive learning	Encoders visual/textual, projeções, normalização L2 e cosine similarity em espaço compartilhado.	Demonstrado
4. CLIP	Ranking com ≥20 conceitos + Top-5	24 conceitos, 600 imagens, threshold 0,22, ranking e exemplos dos 5 mais frequentes.	Demonstrado
4. CLIP	Busca semântica com ≥8 consultas	8 consultas variadas, Top-5 e análise individual dos resultados.	Demonstrado
4. CLIP	CLIP versus BERT; padding e attention mask	Tokenização demonstrada com input_ids/attention_mask e explicação do objetivo multimodal.	Demonstrado
5. GAN/casos	≥5 problemas no projeto de raio-X + impacto	7 problemas: desbalanceamento, split, treino do zero, sem augmentation, LR, métricas e overfitting.	Demonstrado
5. GAN/casos	GAN médica com loop adversarial correto	Conditional DCGAN; fake.detach() em D; target real para G; BCEWithLogitsLoss.	Demonstrado
5. GAN/casos	Instabilidade + mitigação + evidência	Mode collapse visual/quantitativo; LR assimétrico, smoothing, instance noise e Mode-Seeking; diversidade 0,0261.	Demonstrado
5. GAN/casos	Impacto da augmentation sintética no recall COVID	Mesmo teste real: 55,56% baseline versus 38,89% com sintéticos (-16,67 pp).	Demonstrado
5. GAN/casos	≥4 problemas em tráfego + riscos ImageNet	Baixa cobertura, poucas câmeras, correlação temporal, chuva/noite, ângulos e domain shift; split por câmera.	Demonstrado
5. GAN/casos	Plano integrado de melhoria do raio-X	Modelo, métricas, dados, augmentation real/sintética e critérios de adoção clínica.	Demonstrado